

Eksploracja metod uczenia maszynowego do weryfikacji adresów celem usprawnienia procesu zarządzania danymi organizacji

Wprowadzenie

W zarządzaniu informacją i wiedzą podkreśla się znaczenie danych, informacji i wiedzy jako cennych zasobów (lub aktywów) posiadanych przez osoby lub grupy w organizacjach. Ponadto jest to ściśle związane z rozwojem technologii informacyjnych i komunikacyjnych oraz ich rosnącym wpływem na zdolność do przetwarzania, gromadzenia i przesyłania danych, informacji i ludzkiej wiedzy [Haag, Cummings, Dawkins, 1999]. Zarządzanie informacją i wiedzą jest procesem o szerokim wpływie na różne aspekty funkcjonowania organizacji, obejmującym także osoby odpowiedzialne za zapewnienie jakości, dostępności i użyteczności pozyskanych informacji. Dotyczy to zarówno tych, którzy odpowiadają za bezpieczne przechowywanie i usuwanie danych, jak i osób, zaangażowanych w procesy decyzyjne.

Problemy związane z jakością, dostępnością i użytecznością danych mogą być szczególnym wyzwaniem dla organizacji, np. jakość adresów pocztowych jest częstym problemem, przed którym stają organizacje podczas migracji lub integracji danych [Gudivada, Apon, Ding, 2017; Chirkova, Doyle, Reutter, 2021]. Wynika to z faktu, że każdy kraj ma nieco inny system adresów pocztowych, a tym samym „źródło prawdy” danych adresowych. Co więcej, problem ten dotyczy znacznych ilości danych. W Stanach Zjednoczonych istnieje około 160 mln punktów doręczeń [Unangst, McMichael, 2015], 30 mln w Wielkiej Brytanii [Józefowicz, Stone, Aravopoulou, 2020] i 16 mln w Polsce [Wojsyk, Wojsyk, 2023], co obejmuje zarówno adresy zamieszkania, jak i adresy biznesowe, które stale się zmieniają.

Niespójna populacja pól adresów pocztowych w systemach informacji organizacyjnej jest często wynikiem błędów, takich jak nieprawidłowe wprowadza-

nie danych lub niespójne skróty. Częściowo ustrukturyzowany charakter danych adresowych dodatkowo komplikuje proces mapowania źródła do celu, zwłaszcza w przypadku dużych zbiorów danych o różnej jakości [Mercier i in., 2009].

Dlatego w niniejszym rozdziale autorzy badają wykorzystanie algorytmów uczenia maszynowego (*machine learning*, ML) w celu sprostania tym wyzwaniom i usprawnienia procesów zarządzania danymi organizacyjnymi. Przepływ pracy ML składa się z ustalonych iteracyjnie etapów, w tym gromadzenia danych, wstępnego przetwarzania i transformacji, a następnie fazy modelowania, której kulminacją jest wdrożenie modelu uczenia maszynowego w środowisku produkcyjnym. Faza wstępnego przetwarzania i transformacji danych jest uważana za najtrudniejszą część całego procesu, ponieważ zajmuje do 60-80% całkowitego czasu i dostępnych zasobów [Ahuja i in., 2016; Frye, Mohren, Schmitt, 2021]. Etap ten obejmuje typowe zadania, takie jak czyszczenie danych, interpretacja, wyodrębnianie i formatowanie w celu dalszej analizy lub modelowania.

W przypadku danych o niskiej jakości, częściowo ustrukturyzowanych lub wprowadzonych w sposób dowolny, takich jak adresy ulic, brak spójnych standardów lub niezgodności standardów pomiędzy różnymi krajami często skutkują różnorodnymi formatami pól zawierających te same informacje. To z kolei komplikuje etapy wstępnego przetwarzania i transformacji danych. Żmudny oraz podatny na błędy charakter typowego procesu pozyskiwania danych znacząco spowalnia organizację i obniża efektywność ich procesów uczenia maszynowego [Ahuja i in., 2016].

Sytuacja ta wymaga wprowadzenia zmian organizacyjnych oraz bardziej efektywnych metod walidacji adresów. Obecnie stosowane metody walidacji są często subiektywne, niespójne pomiędzy różnymi organizacjami i kosztowne dla firm dążących do poprawy jakości danych w systemach zarządzania relacjami z klientami (CRM), planowania zasobów przedsiębiorstwa (ERP) lub zarządzania zasobami ludzkimi (HRM).

W celu poprawy efektywności organizacyjnej można zastosować różnorodne podejścia do zarządzania informacją w przedsiębiorstwie [Czekaj, 2000]. Jednym z nich jest wprowadzenie organizacyjnego zarządzania danymi, które obejmuje tworzenie potoków walidacji danych na poziomie organizacji [Janssen i in., 2020]. Kolejnym istotnym elementem jest opracowanie korporacyjnego systemu zarządzania bezpieczeństwem informacji, odpowiedzialnego za przydzielanie praw dostępu do przechowywanych danych oraz ograniczanie ich wyłącznie do osób posiadających odpowiednie uprawnienia [Rydz, Krakowiak, Bajor, 2013].

W tym rozdziale autorzy badają, jak zautomatyzować walidację adresów za pomocą metod uczenia maszynowego. Istniejące metody walidacji danych orga-

nizacyjnych często opierają się na logice dopasowywania opartej na regułach, napędzanej „interaktywnymi procesami manualnymi”, które mogą być czasochłonne i niepraktyczne w przypadku zastosowania ich w projektach operujących na dużych zbiorach danych [Cortes, Silveira, Junger, 2021]. Takie reguły zazwyczaj obejmują parsowanie adresów na ich elementy składowe (takie jak nazwa ulicy, miasto, kod pocztowy itp.), stosowanie wzorców w celu dopasowania ich do znanego zestawu adresów i określanie ich dopasowania na podstawie tego, jak dobrze spełniają one określone reguły. Jednakże niewiele badań koncentruje się na wykorzystaniu metod uczenia maszynowego w procesach dopasowywania, przetwarzania i walidacji adresów, zwłaszcza w kontekście zarządzania informacją i wiedzą.

Ahuja i in. [2016] w swoim badaniu dążyli do stworzenia algorytmu identyfikującego kolumny adresowe, a także wykrywającego ich cechy przestrzenne w celu automatycznego formatowania adresów na potrzeby spersonalizowanej usługi ostrzegania o pogodzie w USA. Inne badania koncentrowały się głównie na rozpoznawaniu odręcznych adresów pocztowych [Su, Wang, 2000; Velu, Vivekanandan, 2010; Abid, ul Hasan, Shafait, 2018]. Brakuje jednak badań koncentrujących się na aspekcie walidacji adresów pocztowych w kontekście cyfryzacji, z wykorzystaniem metod uczenia maszynowego w celu poprawy wydajności organizacyjnej.

Podsumowując, ponieważ dane adresów pocztowych i ulicznych wykazują częściowo ustrukturyzowane właściwości, proces mapowania źródła do celu może stanowić wyzwanie, zwłaszcza podczas przetwarzania i/lub utrzymywania dużych zbiorów danych o różnej jakości. W niniejszym rozdziale przeanalizowano proces zautomatyzowanej walidacji adresów, wykorzystując dziesięć algorytmów uczenia maszynowego w połączeniu z zaawansowanymi metodami generowania oraz redukcji cech.

4.1. Materiały i metody

4.1.1. Zbiór danych

Zbiór danych wykorzystany do uczenia maszynowego został przygotowany przy użyciu danych z bazy PAF, pobranej z Royal Mail 6 listopada 2023 roku. PAF to baza danych zawierająca wszystkie znane (prawidłowe) adresy w Wielkiej Brytanii, często określane jako brytyjskie „punkty dostawy” [Józefowicz i in., 2020]. Oprócz PAF, zbiór danych zawiera taką samą liczbę nieprawidłowych adresów wygenerowanych przy użyciu biblioteki programistycznej Faker języka Python [Campesato, 2023]. Więcej szczegółów na temat zbioru danych można znaleźć w tabeli 1.

Tabela 1. Zestaw danych wykorzystany do uczenia maszynowego

Kategoria	Ilość	Źródło
Poprawny	572 128	Postcode Address File
Niepoprawny	572 128	Python Faker Library

Źródło: Opracowanie własne.

4.1.2. Uczenie maszynowe

W badaniu wykorzystano dziesięć algorytmów uczenia maszynowego do walidacji brytyjskich adresów pocztowych, opierając się na referencyjnym zbiorze danych z bazy PAF. Modelowanie i inżynieria cech zostały ułatwione dzięki wykorzystaniu ich istniejącej implementacji w bibliotekach Scikit-learn [Hao, Ho, 2019] i LightGBM [Ke i in., 2017] języka programowania Python. Podsumowanie algorytmów wykorzystywanych w uczeniu maszynowym oraz informację o przeprowadzonym procesie tworzenia czy wybierania zmiennych zastosowanym w naszym procesie przedstawiono w tabeli 2.

Tabela 2. Podsumowanie (1) algorytmów uczenia maszynowego i (2) metod inżynierii cech zastosowanych do weryfikacji poprawności adresów

Algorytmy	Tworzenie i wybór zmiennych
• Maszyna wektorów nośnych (<i>Support Vector Machine</i>) • Drzewa decyzyjne wzmacnianie gradientowo (<i>Gradient Boosted Trees</i>) • Ekstremalnie randomizowane drzewa decyzyjne (<i>Extremely Randomized Trees</i>) • Klasyfikator XGBoost • Drzewa decyzyjne (<i>Decision Trees</i>) • Losowy las (<i>Random Forest</i>) • Sieć neuronowa (<i>Perceptron</i>) • Klasyfikator LightGBM • Klasyfikator SGD • Regresja logistyczna	Wybór cech (trzy główne cechy): • Budynek, • Ulica, • Kod pocztowy. Generowanie funkcji: • Zdefiniowane wyraźne interakcje parami między ulicą a kodem pocztowym. Redukcja cech: • Analiza głównych składowych (<i>Principal Component Analysis</i>) zastosowana do redukcji cech z maksymalnie 25 komponentami

Źródło: Opracowanie własne.

4.2. Rezultaty eksperymentów

Niniejszy rozdział ocenia dziesięć algorytmów uczenia maszynowego i przedstawia je wraz z ich dziewięcioma kluczowymi wskaźnikami oceny przedstawionymi na rys. 2. Mierzymy czas treningu danych, a także wszystkie kluczowe wskaźniki oceny dla problemu klasyfikacji [Hossin, Sulaiman, 2015]. Eksperymenty pokazują, że definiując interakcje parami między cechami reprezentującą-

cymi ulicę a kodem pocztowym oraz redukując cechy za pomocą analizy głównych składowych (PCA), algorytmy osiągnęły dokładność klasyfikacji w zakresie od 63% (jeden algorytm: regresja logistyczna) do 71% (dziewięć algorytmów: maszyna wektorów nośnych, klasyfikatory XGBoost, LightGBM i SGD, algorytmy drzew decyzyjnych, drzewa decyzyjne wzmacniane gradientowo, ekstremalnie randomizowane drzewa decyzyjne, losowy las, sieć neuronowa Perceptron), przy zastosowaniu 10-krotnej walidacji krzyżowej. Model oparty na maszynie wektorów nośnych wymagał treningu przez znacznie dłuższy czas (15 godzin) niż pozostałe algorytmy przedstawione w tym rozdziale; wszystkie one osiągnęły dokładność klasyfikacji na poziomie 71% i F1-Score na poziomie 76% w czasie treningu od 3m 42s (drzewa decyzyjne) do 8m 19s (drzewa decyzyjne wzmacnianie gradientowo). Wskazuje to na skuteczność proponowanego przez nas podejścia, opartego na wykorzystaniu tradycyjnych metod uczenia maszynowego, umożliwiając w przypadku realnej organizacji pełne, cotygodniowe ponowne wytrenowanie modelu na zaktualizowanym zbiorze danych adresowych.


Tabela 3. Szczegółowe podsumowanie rezultatów dla zaproponowanego procesu klasyfikacji adresów

Nazwa	Czas treningu (g:m:s)	Dokładność	Precyzja	Czułość	Miara F1	Log Loss
Maszyna wektorów nośnych	14:59:07	0,71 +/-0,01	0,65 +/-0,01	0,90 +/-0,01	0,76 +/-0,01	0,54 +/-0,01
Drzewa decyzyjne wzmacnianie gradientowo	08:19	0,71 +/-0,01	0,65 +/-0,01	0,90 +/-0,01	0,76 +/-0,01	0,53 +/-0,01
Ekstremalnie randomizowane drzewa decyzyjne	04:53	0,71 +/-0,01	0,65 +/-0,01	0,90 +/-0,01	0,76 +/-0,01	0,54 +/-0,01
Klasyfikator XGBoost	04:44	0,71 +/-0,01	0,65 +/-0,01	0,90 +/-0,01	0,76 +/-0,01	0,53 +/-0,01
Drzewa decyzyjne	03:42	0,71 +/-0,01	0,66 +/-0,01	0,90 +/-0,01	0,76 +/-0,01	0,53 +/-0,01
Losowy las	05:16	0,71 +/-0,01	0,66 +/-0,01	0,90 +/-0,01	0,76 +/-0,01	0,53 +/-0,01
Sieć neuronowa	06:32	0,71 +/-0,01	0,65 +/-0,01	0,91 +/-0,02	0,76 +/-0,01	0,54 +/-0,01
Klasyfikator LightGBM	04:26	0,71 +/-0,01	0,65 +/-0,02	0,90 +/-0,03	0,76 +/-0,01	0,59 +/-0,04
Klasyfikator SGD	03:57	0,71 +/-0,02	0,66 +/-0,03	0,91 +/-0,03	0,75 +/-0,05	0,60 +/-0,01
Regresja logistyczna	03:48	0,63 +/-0,01	0,58 +/-0,01	0,95 +/-0,01	0,72 +/-0,01	0,62 +/-0,001

Podsumowując, analiza uzyskanych rezultatów wskazuje na potencjał zastosowania tradycyjnych metod uczenia maszynowego, takich jak maszyny wektorów nośnych, algorytmy oparte na drzewach decyzyjnych, czy sieciach neuronowych do poprawy jakości danych adresowych w systemach informatycznych typu CRM, ERP czy HRM. Uzyskana wartość miary oceny klasyfikatora F1 na

poziomie 0,76 i dokładności klasyfikacji na poziomie 71% wskazują na wysoką skuteczność wspomnianych metod uczenia maszynowego do automatycznej walidacji adresów. Szczegółowe rezultaty dla wszystkich miar oceny i każdego z algorytmów zadania klasyfikacyjnego przedstawiono w tabeli 3.

Dalszą poprawę rezultatów można osiągnąć poprzez ponowne wytrenowanie modeli na większej ilości danych oraz włączenie do modeli dodatkowych cech, stosując znane metody inżynierii cech. Autorzy uważają, że zaproponowane podejście toruje drogę do usprawnienia walidacji adresów w procesach zarządzania danymi organizacji.



Rys. 1. Szczegółowe wskaźniki oceny jakości klasyfikacji dla wiodącego modelu maszyny wektorów nośnych. Wyniki są praktycznie identyczne dla pozostałych ośmiu badanych algorytmów tradycyjnego uczenia maszynowego (z wyjątkiem regresji logistycznej, osiągającej Miarę F1 na poziomie 72% i dokładność jedynie na poziomie 63%)

4.3. Dyskusja i kierunki dalszych badań

Najnowsze postępy technik uczenia maszynowego pozwalają na wykorzystanie bardziej wyrafinowanych i kosztownych obliczeniowo metod w procesie walidacji i dopasowywania adresów. Rzeczywiście podjęto liczne próby rozwiązania tych problemów, które wykorzystywałyby bardziej złożone głębokie sieci neuronowe w połączeniu z najnowszymi technikami przetwarzania języka naturalnego, takimi jak osadzanie słów lub architektury koder-dekoder.

Różni autorzy donoszą, że uzyskali wskaźniki precyzji i czułości w zakresie od 77% do 83%, co jest o 5-8% lepsze niż istniejące najnowocześniejsze metody dopasowywania adresów [Sharma i in., 2018; Comber, Arribas-Bel, 2019; Shan i in., 2019; Gupta i in., 2021]. Zgodnie z naszą wiedzą, walidacja adresów wydaje się mniej popularnym tematem. Zidentyfikowaliśmy tylko jedno badanie w tym obszarze, oparte na francuskim zbiorze danych adresowych, zawierającym 1 mln elementów. W badaniu tym odnotowano lepszy wynik F1 w zakresie od 92% do 94% dla maszyn wektorów nośnych, algorytmów drzew decyzyjnych, losowego lasu, klasyfikatora XGBoost oraz sieci neuronowej Perceptron, ale wyniki te uzyskano poprzez zastosowanie dodatkowego, złożonego systemu przetwarzania wstępnego, opartego na dwóch metodach osadzania słów: Word2vec i fastText [Guermazi, Sellami, Boucelma, 2020].

W przypadku rzeczonego badania kolejnymi krokami byłoby zatem zastosowanie podobnych podejść wykorzystujących metody osadzania słów poprzez zapisywanie ich w postaci wektorów i eksperymentowanie z coraz bardziej złożonymi klasyfikatorami opartymi na głębokim uczeniu. Interesujące byłoby też porównanie wydajności takich modeli z mniej kosztownym obliczeniowo i lepiej wyjaśnianym tradycyjnym podejściem do uczenia maszynowego. Naszym celem byłoby również stworzenie polskiego zbioru danych, ponowne wytrenowanie modeli i porównanie wyników z francuskim [Guermazi, Sellami, Boucelma, 2020] podejściem, a na koniec zbadanie, jak model wyszkolony dla jednego kraju radzi sobie z danymi z innych jurysdykcji.

Adresy pocztowe są zwykle formatowane inaczej w każdym kraju, co zależy od wykorzystywanego w danej społeczności języka i innych konwencji. Dlatego właśnie spodziewamy się, że model wytrenowany na zbiorze danych z jednego systemu pocztowego i/lub obszaru językowego niekoniecznie będzie działał tak samo dobrze na zbiorach danych adresowych z innych krajów. W chwili obecnej nie istnieje żadna metoda dopasowywania i walidacji adresów oparta na uczeniu maszynowym dla polskiego systemu adresów pocztowych. Jednak polski rynek przesyłek pocztowych rośnie w dwucyfrowym tempie [UKE, 2023] i aby utrzymać tak stabilne tempo wzrostu, z pewnością pożądane jest posiadanie funkcjonującego systemu dopasowywania i walidacji adresów, który mógłby być szeroko stosowany w całej gospodarce. Co więcej, inni autorzy podkreślają również potrzebę cyfryzacji polskich usług pocztowych [Drab-Kurowska, Budziewicz-Guźlecka, 2021], co stanowiłoby podstawę do wdrożenia zaproponowanej metody, opartej na uczeniu maszynowym we wszystkich organizacjach przetwarzających na co dzień duże ilości adresów klientów, dostawców czy pracowników.

Wnioski

Podsumowując, zastosowanie algorytmów uczenia maszynowego do walidacji adresów stanowi obiecujące podejście do wyzwań związanych z jakością adresów w zarządzaniu danymi organizacyjnymi. Wykorzystując techniki uczenia maszynowego, organizacje mogą zwiększyć dokładność i wiarygodność danych adresowych, poprawiając tym samym wydajność i skuteczność różnych systemów i procesów.

W rozdziale zaproponowano obiecujące nowe zastosowanie algorytmów uczenia maszynowego do wstępnej walidacji adresów pocztowych, opierając się na wzorcowym zbiorze brytyjskich danych adresowych (PAF). Algorytmy osiągnęły dokładność na poziomie 71% (10-krotna walidacja krzyżowa), uwzględniając zdefiniowanie interakcji parami między ulicą a kodem pocztowym i zredukowanie cech do 25 komponentów przy użyciu analizy głównych składowych.

Przyszłe badania mogą skupić się na zbadaniu dodatkowych algorytmów klasyfikacji i włączeniu do naszej metody zaawansowanych funkcji wektorowej reprezentacji atrybutów adresu.

Autorzy oczekują, że badania podjęte w tym rozdziale pomogą w ukierunkowaniu praktyków zarządzania, zwłaszcza menedżerów wyższego szczebla i wszystkich tych, którzy w swojej działalności zawodowej nieustannie poszukują w świecie nauki nowych pomysłów na rozwiązanie problemów zarządzania informacją. Przedstawiona metoda może być wykorzystana w projektach migracji lub integracji danych lub w celu poprawy jakości danych adresowych w systemach, takich jak CRM, ERP czy HRM.

Podziękowania

Autorzy pragną podziękować Steve'owi Jenningsowi (dyrektorowi zarządzającemu) i Patrickowi Moore'owi (głównemu analitykowi danych) w firmie Technicus Ltd za dyskusje, które doprowadziły do opracowania opisywanej w tym rozdziale metody walidacji adresów pocztowych opartej na uczeniu maszynowym.

Literatura

- Abid N., ul Hasan A., Shafait F. (2018), *Deepparse: A Trainable Postal Address Parser*, Conference: 2018 Digital Image Computing: Techniques and Applications (DICTA).
- Ahuja S., Roth M., Gangadharaiah R., Schwarz P., Bastidas R. (2016), *Using Machine Learning to Accelerate Data Wrangling*, 16th International Conference on Data Mining Workshops (ICDMW), IEEE.

- Campeato O. (2023), *Data Literacy with Python*, Stylus Publishing, LLC.
- Chirkova R., Doyle J., Reutter J.L. (2021), *Ensuring Data Readiness for Quality Requirements with Help from Procedure Reuse*, „Journal of Data and Information Quality”, Vol. 13(3).
- Comber S., Arribas-Bel D. (2019), *Machine Learning Innovations in Address Matching: A Practical Comparison of word2vec and CRFs*, „Transactions in GIS”, Vol. 23(2), s. 334-348.
- Cortes T.R., Silveira I.H. d., Junger W.L. (2021), *Improving Geocoding Matching Rates of Structured Addresses in Rio de Janeiro, Brazil*, „Cadernos de Saúde Pública”, Vol. 37(7).
- Czekaj J. (2000), *Metody zarządzania informacją w przedsiębiorstwie*, Wydawnictwo Akademii Ekonomicznej w Krakowie, Kraków.
- Drab-Kurowska A., Budziewicz-Guźlecka A. (2021), *The Digital Post Ecosystem – Example of Poland in the Context of Research*, „Sustainability”, Vol. 13(5).
- Frye M., Mohren J., Schmitt R.H. (2021), *Benchmarking of Data Preprocessing Methods for Machine Learning-Applications in Production*, „Procedia CIRP”, Vol. 104, s. 50-55.
- Gudivada V.N., Apon A.W., Ding J. (2017), *Data Quality Considerations for Big Data and Machine Learning: Going Beyond Data Cleaning and Transformations*, „International Journal on Advances in Software”, Vol. 10(1-2).
- Guermazi Y., Sellami S., Boucelma O. (2020), *Address Validation in Transportation and Logistics: A Machine Learning Based Entity Matching Approach* [w:] ECML PKDD 2020 workshops, s. 320-334.
- Gupta V., Gupta M., Garg J., Garg N. (2021), *Improvement in Semantic Address Matching Using Natural Language Processing*, 2021 2nd International Conference for Emerging Technology (INCET), IEEE.
- Haag S., Cummings M., Dawkins J. (1999), *Management Information Systems for the Information Age*, McGraw-Hill Higher Education.
- Hao J., Ho T.K. (2019), *Machine Learning Made Easy: A Review of Scikit-learn Package in Python Programming Language*, „Journal of Educational and Behavioral Statistics”, Vol. 44(3), s. 348-361.
- Hossin M., Sulaiman M.N. (2015), *A Review on Evaluation Metrics for Data Classification Evaluations*, „International Journal of Data Mining & Knowledge Management Process”, Vol. 5(2).
- Janssen M., Brous P., Estevez E., Barbosa L.S., Janowski T. (2020), *Data Governance: Organizing Data for Trustworthy Artificial Intelligence*, „Government Information Quarterly”, Vol. 37(3).
- Jozefowicz S., Stone M., Aravopoulou E. (2020), *Geospatial Data in the UK*, „The Bottom Line”, Vol. 33(1), s. 27-41.

- Ke G., Meng Q., Finley T., Wang T., Chen W., Ma W., Ye Q., Liu T.-Y. (2017), *LightGBM: A Highly Efficient Gradient Boosting Decision Tree* [w:] I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, R. Garnett (eds.), *Advances in Neural Information Processing Systems* 30.
- Mercier D., Cron G., Denux T., Masson M.-H. (2009), *Decision Fusion for Postal Address Recognition Using Belief Functions*, „Expert Systems with Applications”, Vol. 36(3), s. 5643-5653.
- Rydz D., Krakowiak M., Bajor T. (2013), *Zapewnienie bezpieczeństwa informacji w przedsiębiorstwach*, „Prace Naukowe Akademii im. Jana Długosza w Częstochowie. Technika, Informatyka, Inżynieria Bezpieczeństwa”, t. 1, s. 281-287.
- Shan S., Li Z., Qiang Y., Liu A., Xu J., Chen Z. (2019), *DeepAM: Deep Semantic Address Representation for Address Matching* [w:] J. Shao, M.L. Yiu, M. Toyoda, D. Zhang, W. Wang, B. Bui (eds.), *Web and Big Data*, Springer International Publishing, Cham, s. 45-60.
- Sharma S., Ratti R., Arora I., Solanki A., Bhatt G. (2018), *Automated Parsing of Geographical Addresses: A Multilayer Feedforward Neural Network Based Approach*, [w:] 2018 IEEE 12th International Conference on Semantic Computing (ICSC), Laguna Hills, s. 123-130.
- Su Y.-M., Wang, J.-F. (2000), *A New Multistage Classification Scheme for Recognition of Postal Road /Street Names*, „Journal of the Chinese Institute of Engineers”, Vol. 23(5), s. 653-664.
- UKE (2023), *Raport o stanie rynku pocztowego w 2022 r.*, Urząd Komunikacji Elektronicznej, <https://www.uke.gov.pl/akt/raport-o-stanie-ryнку-pocztowego-w-2022-r-482.html> (dostęp: 13.02.2024).
- Unangst J., McMichael J. (2015), *Tracking and Evaluating Changes to address-based sampling frames over time* [w:] Proceedings of the 2015 Joint Statistical Meetings, Section on Survey Research Methods, American Statistical Association, s. 4310-4316.
- Velu C., Vivekanandan P. (2010), *Automatic Letter Sorting for Indian Postal Address Recognition System Based on Pin Codes*, „Journal of Internet and Information System”, Vol. 1(1), s. 6-15.
- Wojsyk K., Wojsyk J. (2023), *Use of Universal Address to Ensure High-Quality Data*, „GIS Odyssey Journal”, Vol. 3(1), s. 5-18.